




ESCUELA TÉCNICA
SUPERIOR DE INGENIEROS
INFORMÁTICOS



 <https://medal.ctb.upm.es/>

 @MEDAL_CTB

MedSymbolicLLM: a Hybrid AI System for Normalizing Medical Entities in an Explainable Manner

Master's Thesis
Master Degree in Data Science

Álvaro García Barragán

Tutorized by
Academic tutor: Ernestina Menasalvas Ruiz
External tutor: Víctor Robles Forcada

Madrid, July 2024

Tabla de contenidos

01 Introducción

02 Estado de la cuestión

03 Planteamiento del problema

04 MedSymbolicLLM

05 Validación

06 Conclusión & Trabajo Futuro

01 INTRODUCCIÓN


Datos sanitarios

- Los hospitales producen un promedio de **50 petabytes de datos** cada año [2].
- Aproximadamente el **30% del volumen de datos** del mundo es generado por la industria de la salud [3].




Sistemas de Información de Atención Médica (HCIS)

- Los datos se pueden clasificar en dos categorías:
 - **Datos estructurados.**
 - Ejemplos: datos demográficos o medicamentos recetados.
 - **Datos no estructurados.**
 - Ejemplos: historias clínicas o imágenes médicas.
- Alrededor del **80%** del total de datos en los hospitales **no están estructurados** [6].
 - No existe la interoperabilidad.
 - Incluyen información valiosa como juicios clínicos o tratamientos.



Interoperabilidad en ámbito sanitario

- Intercambio de datos fluido que permite una mejor coordinación de la atención de pacientes.
- **Mejora de la atención al paciente:** permite que los proveedores de atención médica accedan a registros completos de pacientes.
 - Mejor toma de decisiones clínicas.
- **Ahorro de costes:** minimiza la necesidad de duplicar pruebas y procedimientos al proporcionar información completa del paciente.




Normalización médica

- Los modelos de **Reconocimiento de Entidades Nombradas (NER)** son solo el primer paso para convertir los registros clínicos en información estructural, ya que la **normalización médica** es necesaria después del paso NER.
- Para realizar la normalización médica, también se pueden considerar enfoques de Aprendizaje Profundo (DL). Sin embargo, estos no son interpretables.

Paciente de 57 años que asiste a consulta.

Diagnosticada con **carcinoma** **CANCER_CONCEPT** **ductal** **CANCER_TYPE** **infiltrante** **CANCER_EXP** de **mama derecha** **CANCER_LOC** .

Tratada con **quimioterapia** **TRAT** desde hace un mes.



Medical Normalization

¿Cómo se puede hacer que DL sea interpretable?

Historial
normalizado



Normalización médica: Vocabularios médicos

- Un **historial normalizado** está formado por conceptos de un vocabulario.
- Un **vocabulario** médico es un conjunto de **conceptos**.
- Dada una **entidad**, puede convertirse en más de un concepto.
- Cada concepto tiene un **identificador único** (ID) que permite la interoperabilidad.


carcinoma → {ID1, ID2}

ductal → {ID2, ID3}

infiltrante → {ID4}

mama derecha → {ID5, ID6, ID7}


Entidades



**Identificadores
de Concepto**

Objetivos

- Desarrollo de un sistema capaz de normalizar un conjunto de entidades obtenidas de un modelo NER a un conjunto de conceptos clínicos normalizados de forma explicable.
- Evaluar el rendimiento del sistema comparándolo con otras herramientas.



- Validar el método a través de un caso de estudio. El trabajo utilizará un corpus de cáncer de mama y el *Unified Medical Language System* (UMLS) como vocabulario seleccionado.

02


ESTADO DE LA CUESTIÓN

Estado de la cuestión: *BERT*

-
- % Accuracy
- +
- Existen varias formas de normalizar el texto libre (entity linking – EL)
 - *Recuperación de información (IR)*: TF-IDF o BM25
 - Busque una palabra en una base de datos ad-hoc con una medida de similitud entre cadenas.
 - *Aprendizaje automático (ML)*: Aprendizaje supervisado
 - Ajuste fino de BERT (necesita anotación de corpus)
 - **Etiquetado de secuencias**: hacer NER con identificadores de vocabulario.
 - Problema: hay muchos conceptos en un vocabulario.
 - **Word embeddings**
 - Entrenar un modelo que prediga la similitud entre conceptos y entidades.


Estado de la cuestión: *en busca de la interpretabilidad*

- Tres enfoques posibles:
 1. Sistemas de **IA simbólica**, tienen el problema de que las entidades en el texto pueden diferir de las etiquetas en los vocabularios.
 - Por faltas de ortografía.
 - O que un concepto se puede escribir de muchas maneras (vocabularios que no tienen todas las formas posibles para escribir el mismo concepto).
 2. Sistemas de **IA subsimbólica** son mejores, pero el entrenamiento de un modelo necesita datos anotados y este enfoque se basa en el Aprendizaje Profundo (DL) pero *no es interpretable*.
 3. Sistemas **híbridos**: combinar enfoques simbólicos y subsimbólicos para aprovechar las fortalezas de ambos.



Estado de la cuestión: *LLMs un enfoque interpretable*

- Dado que los LLM son "máquinas inteligentes", les podemos hacer explicar su razonamiento.
- *CoT prompting* es mejor que *prompting estandar*, permite hacer razonar.



"Chain-of-thought prompting elicits reasoning in large language models" Wei et al. (2023)

03

PLANTEAMIENTO DEL PROBLEMA

Hipótesis

Hipótesis


La normalización de una entidad médica y su etiqueta asociada a un concepto estandarizado utilizando un modelo grande de lenguaje mejorará las técnicas de normalización actuales y proporcionará interpretabilidad.




Hay información útil en notas no estructuradas en los EHRs (Historias Clínicas Electrónicas)

Estructuración de información médica: NER + MCN

- Este TFM es la continuación del trabajo previo del TFG.
 - En el TFG se hizo el reconocimiento de entidades con BERT.
 - En este trabajo se va a realizar el módulo MCN.



Estructuración de información médica: ¿Para qué?



“Guidelines for scientific evidence provision for policy support based on Big Data and open technologies.” Grazzini et al. (2015)

1. **Datos:** texto libre escrito por un médico "paciente tuvo cáncer de mama durante dos años y el tratamiento con Doxorubicina, logro detenerlo"
2. **Información:**
 - Diagnóstico: cáncer de mama
 - Tratamiento: doxorubicina
 - Status: Éxito
3. **Conocimiento:**
 - Doxorubicina -> cáncer de mama -> éxito
4. **Sabiduría:** utilizarlo en otros pacientes en el mismo caso.

Normalización Medica de Entidades (MCN)

- MCN es una función f que tiene que ser capaz a partir de una entidad e y una etiqueta l obtenida de un modelo de NER, devolver el conjunto de identificadores que representa esa mención.
- La etiqueta l esta definida por médicos y la entidad e aparece en una nota clínica.

$$f(e, l) = J$$

$$f(\text{"lobulillar"}, \text{"Cancer Type"}) = \{\text{"C0206692"}, \text{"C0205417"}\}$$

Retos: complejidad del lenguaje natural

- **Variabilidad ortográfica:** aparece cuando un mismo concepto se escribe de diferentes maneras.
 - *Faltas de ortografía:* se corresponde en errores en la ortografía de las palabras. Por ejemplo, la palabra "carcinom" es un error ortográfico de la palabra "carcinoma" habiendo omitido la última letra.
 - *Acrónimos y abreviaturas:* se utiliza para simplificar y acortar las formas escritas o habladas de terminología compleja o extensa. Un ejemplo de acrónimo es "BAG" que significa "biopsia con aguja gruesa".

Retos: complejidad del lenguaje natural

- **Variabilidad semántica:** aparece cuando un concepto o idea se expresa utilizando diferentes palabras.
 - *Sinonimia:* describe la conexión entre palabras que poseen significados idénticos o casi idénticos. Por ejemplo “neoplasia epitelial maligna” y “carcinoma”.
 - *Homonimia:* se produce cuando varias palabras tienen una ortografía idéntica, pero tienen significados diferentes dependiendo del contexto. Por ejemplo, la palabra “mama”.

Retos: complejidad del lenguaje natural

- Los vocabularios médicos están formados por una **gran cantidad de conceptos médicos**, que van cambiando según el lenguaje o la ciencia evoluciona.
- En UMLS la palabra “carcinoma” aparece en más de 40,000 términos.

40,292 hits


_source																								
>	label:	carcinoma	de ovário	cui:	C0029925	lang:	POR	freq:	1	has_def:	false	sgroup:	DISO	stype:	T191	_id:	-1_R04oBHXXHnChAhImm	_type:	-	_index:	umls	_score:	0	
>	label:	carcinoma	of ovary (diagnosis)	cui:	C0029925	lang:	ENG	freq:	1	has_def:	false	sgroup:	DISO	stype:	T191	_id:	AF_R04oBHXXHnChAhIqm	_type:	-	_index:	umls	_score:	0	
>	label:	carcinoma	ovárico	cui:	C0029925	lang:	SPA	freq:	1	has_def:	false	sgroup:	DISO	stype:	T191	_id:	AV_R04oBHXXHnChAhIqm	_type:	-	_index:	umls	_score:	0	
>	label:	ovarialis	carcinoma	cui:	C0029925	lang:	HUN	freq:	1	has_def:	false	sgroup:	DISO	stype:	T191	_id:	B1_R04oBHXXHnChAhIqm	_type:	-	_index:	umls	_score:	0	
>	label:	carcinoma	pulmonar ovino	cui:	C0034049	lang:	POR	freq:	2	has_def:	true	sgroup:	DISO	stype:	T047	_id:	5GDR04oBHXXHnChAkNZU	_type:	-	_index:	umls	_score:	0	
>	label:	carcinoma	pulmonar ovino	cui:	C0034049	lang:	SPA	freq:	2	has_def:	true	sgroup:	DISO	stype:	T047	_id:	5WDR04oBHXXHnChAkNZU	_type:	-	_index:	umls	_score:	0	
>	label:	cell, embryonal	carcinoma	cui:	C0013485	lang:	ENG	freq:	1	has_def:	true	sgroup:	ANAT	stype:	T025	_id:	SFrR04oBHXXHnChAWxZF	_type:	-	_index:	umls	_score:	0	
>	label:	células madre de	carcinoma	embrionario	cui:	C0013485	lang:	SPA	freq:	1	has_def:	true	sgroup:	ANAT	stype:	T025	_id:	VvR04oBHXXHnChAWxZF	_type:	-	_index:	umls	_score:	0
>	label:	carcinoma	yolk sac	cui:	C0014145	lang:	ENG	freq:	1	has_def:	true	sgroup:	DISO	stype:	T191	_id:	GlR04oBHXXHnChAW1ZN	_type:	-	_index:	umls	_score:	0	
>	label:	embryonal	carcinoma, infantile	cui:	C0014145	lang:	ENG	freq:	2	has_def:	true	sgroup:	DISO	stype:	T191	_id:	H1rR04oBHXXHnChAW1ZN	_type:	-	_index:	umls	_score:	0	

04 MedSymbolicLLM

MedSymbolicLLM



Un Sistema de IA Neuro-Simbólica para normalizar entidades médicas.

- Dos módulos, 3 pasos:
 - a) Modulo simbólico
 1. **Generación de candidatos:** Buscar en el BK la entidad médica y obtener los conceptos candidatos más similares.
 2. **Decisión heurística:** Deducir si existe la solución o es necesario desambiguar.
 - b) Modulo sub-simbólico
 3. **Desambiguación:** seleccionar a los candidatos más apropiados dado un contexto con un LLM.



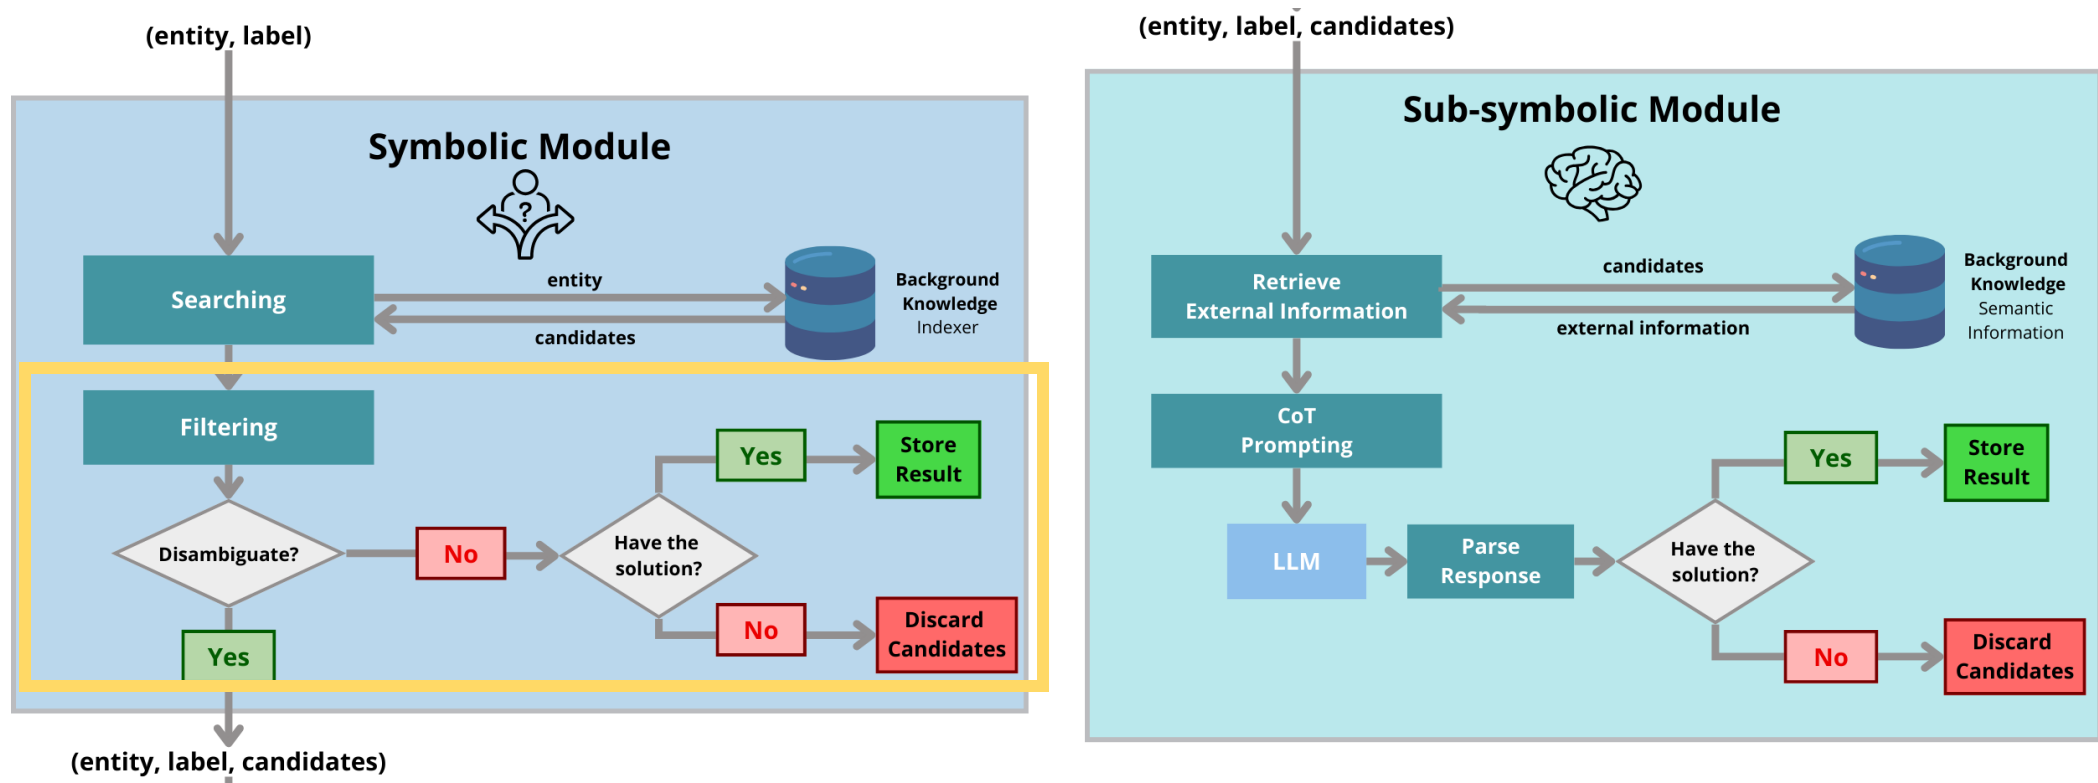
MedSymbolicLLM

- Dos módulos, 3 pasos: **1. Generación de candidatos**, 2. Decisión heurística 3. Desambiguación
 - Algoritmo BM25 con búsqueda *fuzzy*, para buscar los candidatos más similares, aborda el problema de errores ortográficos.



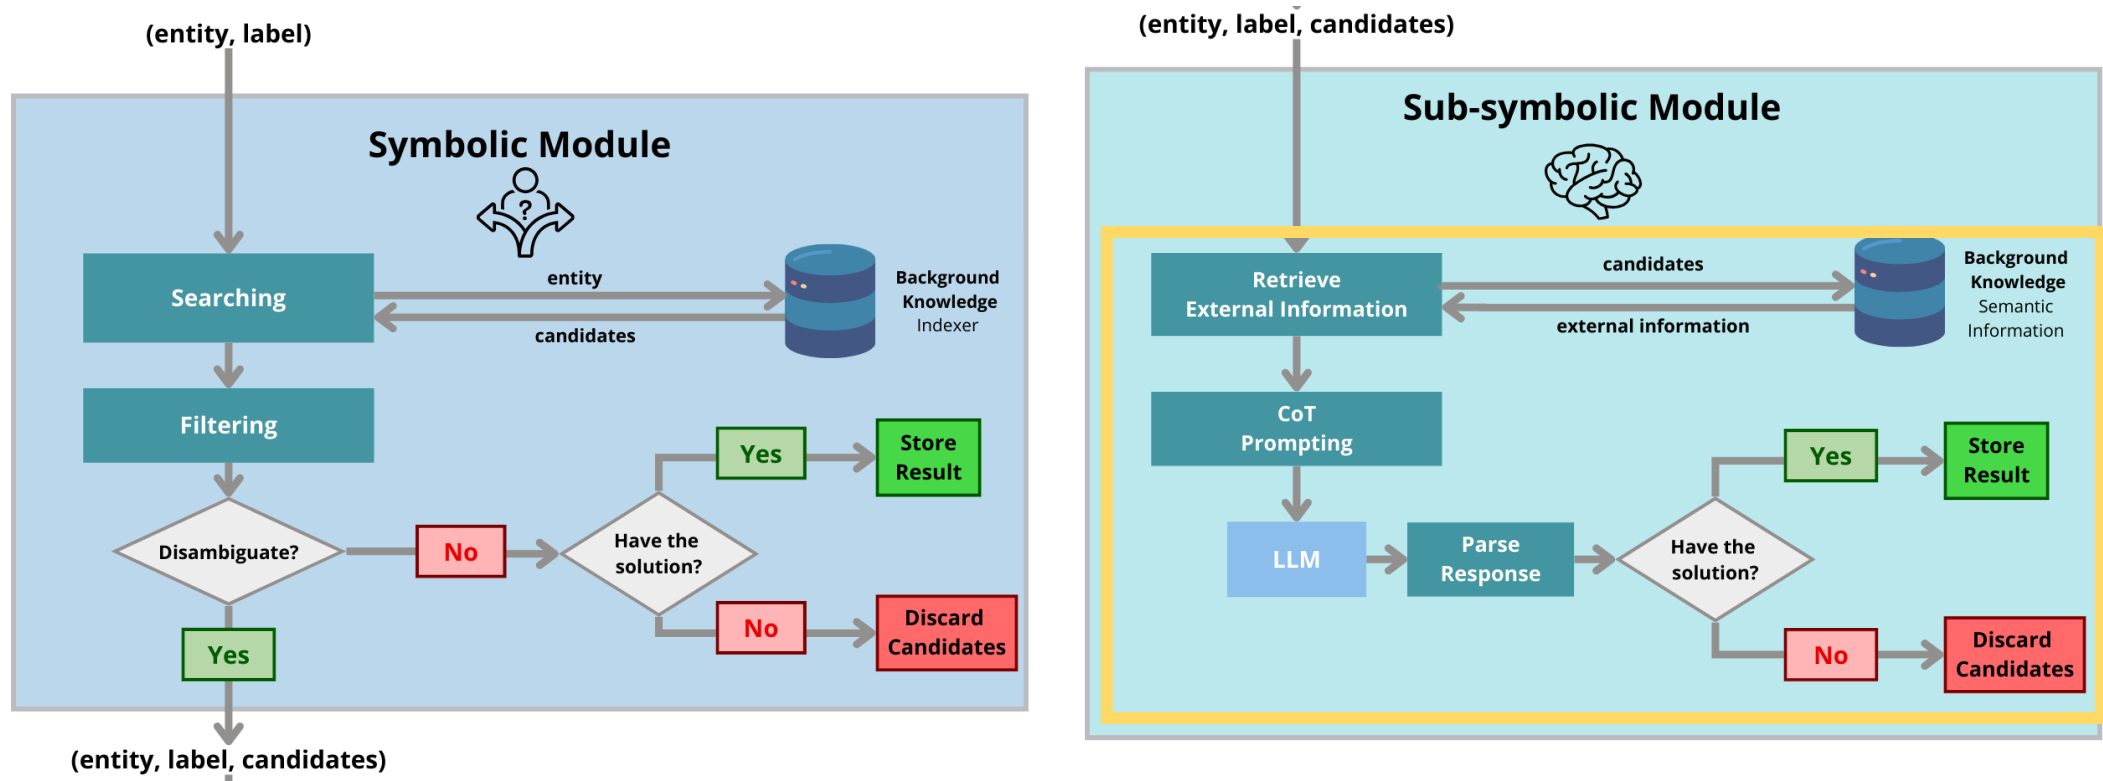
MedSymbolicLLM

- Dos módulos, 3 pasos: 1. Generación de candidatos, **2. Decisión heurística**, 3. Desambiguación
 - Se filtran los candidatos con una función de similaridad y si hay candidatos por encima del umbral para un único contexto la solución ya está. Sino desambiguar.



MedSymbolicLLM

- Dos módulos, 3 pasos: 1. Generación de candidatos, 2. Decisión heurística, **3. Desambiguación**
 - Se genera un prompt y se manda al LLM para desambiguar la entidad.



05 VALIDACIÓN

Caso de Estudio

- Validación del sistema con un caso de estudio de diagnóstico de cáncer de mama.
- Fases
 1. Set up para validar el sistema.
 - a. Seleccionar un vocabulario.
 - b. Crear un benchmark.
 - c. Seleccionar LLMs.
 - d. Seleccionar parámetros del Sistema.
 2. Experimentos guiados por preguntas de investigación (RQs)
 - **RQ1:** ¿Cuánto más preciso es MedSymbolicLLM en comparación con otros enfoques en la tarea de normalizar entidades?
 - **RQ2:** ¿Se puede interpretar el proceso de normalización de entidades proporcionado por el LLM por humanos?

Cáncer de mama



Más prevalente entre las mujeres a nivel mundial

2022: 2,26 millones de mujeres diagnosticadas en todo el mundo

Set up: Vocabulario Médico

- *UMLS - Unified Medical Language System*
 - *¿Por qué?*
 - **Cobertura Total:** Integra una amplia gama de terminologías médicas, clasificaciones y estándares de codificación.
 - **Interoperabilidad:** incluye 150 vocabularios controlados en las ciencias biomédicas, como los vocabularios SNOMED-CT y ICD.
 - **Amplia aceptación:** es ampliamente reconocido y adoptado en la comunidad de investigación médica y sanitaria.
 - *¿Qué?*
 - Vocabulario Methasaurus: formado por otros vocabularios.
 - A cada concepto médico se le asigna un Identificador Único de Concepto (CUI)
 - Adicionalmente tienen un grupo semántico como anatomía o enfermedades.



Set up: *Corpus Cáncer de Mama*

- Corpus propio que contiene notas clínicas de casi **600 pacientes** con cáncer de mama [53].
- Todas las notas corresponden a la categoría de **juicio clínico**, redactadas por médicos de un hospital público.
- Un total de **17.986 entidades** (excluimos algunas entidades).

Label	Support	Vocab size
Cancer Concept	826	32
Cancer Type	558	24
Cancer Subtype	75	26
Cancer Expansion	650	25
Cancer Location	1645	249
Cancer Metastasis	369	31
Cancer Recurrence	44	6
Molecular Marker	1691	620
Cancer Stage	344	35
TNM	594	467
Treatment Name	351	58
Treatment Schema	96	19
Treatment Drug	475	110
Treatment Frequency	43	12
Treatment Quantity	56	36
Surgery	888	88
Total	8600	1824

Breast-NER-Benchmark

Set up: Corpus Cáncer de Mama

- *Breast-Norm-Benchmark* se ha creado a partir de *Breast-NER-Benchmark*.
 - Solo seleccionando las entidades únicas.
 - Solo seleccionando las entidades que se han podido normalizar.
- Teniendo un total de **438 entidades** normalizadas a sus correspondientes CUIs.
- Ejemplo:
 - **Texto:** “mastectomía ahorradora”
 - **Contexto:** “Surgery” CUIs: “{‘C0024881’, ‘C1997268’}”

Label	Support
Cancer Concept	25
Cancer Expansion	14
Cancer Location	151
Cancer Subtype	19
Cancer Type	18
Surgery	69
Treatment Drug	96
Treatment Name	46
Total	438

Breast-Norm-Benchmark

Set up: *LLMs del estudio*

- Dos LLMs diferentes propósitos:
 - **GPT-4** (Número desconocido de parámetros)
 - Código cerrado y basado en la nube.
 - Multimodal y propósito general.
 - **BioMistral-7B**
 - Código libre y desarrollo local.
 - Adaptado para el ámbito médico utilizando el Subconjunto de Acceso Abierto de PMC (PubMed Central).



Set up: *Prompting*

- Se le suministra al modelo todo el contexto necesario para realizar la desambiguación,
 - **Dominio medico**: Diagnostico de Cáncer de Mama.
 - **Vocabulario**: Nombre del vocabulario
 - **Contexto**: Etiqueta NER.
- Se usa la técnica de **prompting CoT** para pedir una explicación.

Task Role

System: You are an assistant and a skilled linguist specialized in entity linking text to a vocabulary.
In the background of the domain *<domain>*.

Task Description and Format

System: Choose the best concepts of *<vocabulary>* for the entity *<entity>* and the context *<label>*
Ensure that all the words are present in the term and nothing more.
In the case where two candidates are synonyms, return both in the order with more coincidence, considering the clauses and the context. The output should be always in the following format and **every answer need an explanation**:

- If you, think the answer is in the candidates return it in this format:
candidates=[Identifier], explanation="text explaining why you take this decision"
- In case of not found the best return: candidates=[None], explanation="text explaining why you take this decision of not having candidates"

Set up: *Prompting*

- Se proporcionan dos ejemplos uno positivo y uno negativo con sus correspondientes explicaciones. Fijos para todas las futuras inferencias.
- Importante recordar que los roles son formas en los que se le enseña al LLM para codificar el chat, pero en última instancia se le envía texto y devuelve texto.

Few-shot
Samples

User: Positive example: List of candidates with the corresponding semantic context.

Assistant: candidates=["ConceptIdentifier"], explanation="I selected this identifier because..."

User: Negative example: List of candidates with the corresponding semantic context.

Assistant: candidates=[None], explanation="I did not select anyone because ..."

Input Task

User: Task to solve. Entity: <entity> Context: <label> Candidates: <candidates>

Set up: *Parámetros del sistema*

- Parámetros del sistema configurado en una evaluación de tres pasos secuencial.
- Se ha optimizado el sistema para comprobar que los candidatos del *Ground Truth* se encuentran en las salidas de cada módulo:
 1. La consulta al BK.
 2. El umbral del módulo de filtrado.
 3. El prompt para el LLM.

Experimentos: *RQ1*

- MedSymbolicLLM devuelve directamente las mejores CUI que encuentra, normalmente un número muy limitado (1, 2 o 3), mientras que BioFalcon y scispaCy devuelven los top-N CUIs.

$$\text{Accuracy@N} = \frac{|G \cap R_{\text{top-N}}|}{|G|}$$

- MedSymbolicLLM con GPT-4 es la herramienta más precisa para la normalización de conceptos médicos, demostrando un rendimiento superior en la identificación de conceptos correctos dentro de las cinco predicciones.

Tool	Model	Accuracy@5 (%)
scispaCy	en_core_sci_sm	33.78
	en_core_sci_lg	31.73
	en_core_sci_scibert	33.78
Falcon 2.0	BioFalcon	66.01
MedSymbolicLLM	BioMistral	64.84
	GPT-4	80.32

Experimentos: *RQ2*


- Ambos modelos **dan explicaciones acordes a la tarea que se les pide**, pero tienen diferencias que puede justificarse por la gran diferencia en número de parámetros.
 - BioMistral 7B**: menos creativo se ajusta más al formato de los ejemplos del prompt. En algunos casos es menos plausible ya que el razonamiento es escueto. Esto provoca que en algunos casos la fidelidad del razonamiento no sea la apropiada.
 - GPT-4**: es más convincente en sus explicaciones, no presenta alucinaciones siendo fiel a la tarea a resolver.

Id	Model	Explanation	Prediction	P	F
1	BioMistral	Because 'carcinoma ductal de mama' is the same as 'ductal' carcinoma of the breast	C1527349, C1134719	2	2
	GPT-4	The terms 'carcinoma ductal de mama' and 'carcinoma ductal da mama' both contain the word 'ductal', are classified under DISO (Disease), and specifically refer to a type of breast cancer, aligning with the 'Cancer Type' context. Both CUIs describe the same condition despite minor variations in the label, fulfilling the requirement for exact matching in the context.	C1527349, C1134719	3	3
2	BioMistral	The definition of the CUI C0222601 is the same as the input text	C0222601	3	2
	GPT-4	Both candidates specify 'mama izquierda' which perfectly matches the term and the context as both are labeled under the ANAT semantic group, focusing purely on anatomical locations necessary for discussing cancer locations.	C0222601, C1284139	3	3

$$Fidelidad = \{1, 2, 3\} \quad Plausibilidad = \{1, 2, 3\}$$

05 CONCLUSIÓN & TRABAJO FUTURO

Conclusión



MedSymbolicLLM, un sistema híbrido de IA capaz de normalizar entidades médicas.

Siendo un modelo XAI (*eXplanaible Artificial Intelligence*)

Flexible para diferentes vocabularios y dominios médicos

Teniendo en cuenta la privacidad de los datos



Mejor precisión que scispaCy y BioFalcon.

Al menos cercano a un 15% más.



A más grande sea el LLM, mejor realiza la desambiguación médica.

Como es de esperar ya que tiene más parámetros.

Trabajo Futuro



Prompt-instruct finetuning para realizar la desambiguación de entidades.



Uso de los LLMs avanzados más nuevos que salen cada semana.




Incorporar BK información de sinónimos y acrónimos para tratar el vocabulario específico de cada hospital.



Usar MedSymbolicLLM en toda la base de datos de un hospital para obtener información estructurada.



ESCUELA TÉCNICA
SUPERIOR DE INGENIEROS
INFORMÁTICOS



 <https://medal.ctb.upm.es/>

 @MEDAL_CTB

MedSymbolicLLM: a Hybrid AI System for Normalizing Medical Entities in an Explainable Manner

Master's Thesis
Master Degree in Data Science

Álvaro García Barragán

Tutorized by
Academic tutor: Ernestina Menasalvas Ruiz
External tutor: Víctor Robles Forcada

Madrid, July 2024