



“PREDICCIÓN DEL ESTADO DE SALUD POBLACIONAL MEDIANTE MODELOS DE MACHINE LEARNING”

HITO-1

Álvaro Barragan, Gonzalo Potel y Sandra Pinel

Máster en Bioinformática y Ciencia de Datos en Medicina Personalizada y de Precisión

1 CONTEXTO Y OBJETIVO

¿Por qué es importante predecir el estado de salud?

Prevención sanitaria

Planificación del
sistema sanitario

Identificación factores
de riesgo

PROBLEMA

- Información difícil de obtener → **ENCUESTAS**
- } • Costosas
• Requieren tiempo



OBJETIVO

Desarrollar un **modelo de ML** capaz de estimar el estado de salud a partir de variables disponibles en entornos clínicos e identificar factores influyentes

HIPÓTESIS

El estado de salud de los individuos puede inferirse a partir de sus características clínicas, existiendo variables más relevantes que otras en dicha predicción.

2 DATASET: ENCUESTA DE SALUD DE ESPAÑA 2023

recoge información sobre el estado de salud, uso de servicios sanitarios y factores determinantes en una muestra representativa de la población.



Desarrollada por:

INē

Instituto Nacional de Estadística



3 CUESTIONARIOS

- CUESTIONARIO DE HOGAR
- **CUESTIONARIO DE ADULTO**
- CUESTIONARIO DE MENOR

El dataset seleccionado es el de adultos (> 15 años) y cuenta con 21,032 pacientes con 432 características.

3 LIMPIEZA DE DATOS

Step	Pacientes (Filas)	Características (Cols)
1. Inicial	21,032	432
2. Borrar metainformación no clinica (proxys, IDENTHOGAR)	21,032	424
3. Borrar columnas con >5 nulos	21,032	164
4. Borrar filas con nulos	20,598	164

4 Exploración de Datos (EDA)


Variables Seleccionadas para EDA

- Como el dataset tiene 165 variables, se seleccionaron las variables con mayor coeficiente de *correlación de Pearson* (top 15) con la variable objetivo
- Además variables de interés demográfico como la comunidad autónoma, edad y sexo

	G7	ÍNDICE BIENESTAR	C3a	F7	K1	F6	C4	EDADa	I1	SEVERIDAD DEPRESIVA	F8	J1	J9	I3
cor (x,y)	0.56	0.51	0.49	0.47	0.43	0.43	0.39	0.38	0.37	0.35	0.34	0.28	0.27	0.27



Distribución de variable objetivo: Estado de Salud

- Estado de salud multiclase ordinal 1 (muy bueno) a 5 (muy malo)
- Clases no balanceadas donde el ~ 50% de pacientes tienen estado bueno (2)



Distribuciones demográficas


- Pacientes con edad mediana 55 años
- 55% Mujeres y 45% Hombres



Edad Mediana en Europa vs España

- Población de pacientes envejecida (55 años nuestro dataset)
 - Edad mediana en España 2020: 44 años
 - Edad mediana de la población en la UE 2020: 44 años
 - Mediana Mundial 30 años

https://www.ine.es/prodyser/demografia_UE/bloc-1c.html?lang=es



Fuente: Eurostat - [acceso al conjunto de datos](#)


Distribución geográfica de pacientes

- Pacientes pertenecientes a todas las comunidades autónomas (19)
- La mayoría de pacientes son de Madrid, Andalucía y Barcelona, comunidades mas pobladas





Distribuciones: Comunidad Autónoma y Estado de Salud

- Distribución uniforme del estado de salud dado la comunidad autónoma



Correlación variable objetivo

- Correlación positiva:
 - A más edad peor estado de salud
 - A más grado de dolor en últimos 4 meses (G7) peor estado de salud
- Correlación negativa
 - A más tiempo desde la última consulta (I3) mejor estado de salud




G7	Descripción
1	Ninguno
2	Muy leve
3	Leve
4	Moderado
5	Severo
6	Extremo


I3	Descripción
1	< 4 semanas
2	Entre 4 semanas y 12 meses
3	> 12 meses
4	Nunca
9	No contesta

Distribuciones: Índice de Bienestar

- Encuesta de Warwick-Edinburgh
- Puede estar sesgado por grupo con bienestar muy elevado




Severidad Depresiva



Código		Descripción
595	1	Ninguna
596	2	Leve
597	3	Moderada
598	4	Moderadamente Grave
599	5	Grave
600	9	No consta

- Muchos sin depresión
- Muy pocos con depresión grave
- 3% de las personas no contestaron


Consumo de Medicamentos Recetados En Las Últimas Dos Semanas



Código Descripción		
61	1	Sí
62	2	No

- 59.4% Sí
- 40.6% No

Correlación Con la Variable Objetivo



Variables con mayor fuerza predictiva:

- Índice de bienestar $\rightarrow -0.47$

A $\uparrow$ bienestar $\downarrow$ C1

- Severidad depresiva $\rightarrow 0.43\uparrow$

A $\uparrow$ severidad depresiva $\rightarrow$ C1




“PREDICCIÓN DEL ESTADO DE SALUD POBLACIONAL MEDIANTE MODELOS DE MACHINE LEARNING”

HITO-2

Álvaro Barragan, Gonzalo Potel y Sandra Pinel

Máster en Bioinformática y Ciencia de Datos en Medicina Personalizada y de Precisión

Recapitulación



OBJETIVO

Estimar el estado de salud a partir de variables clínicas usando ML. Identificar factores influyentes.

DATASET LIMPIO

Selección de adultos. De 432 características a 164 variables de valor clínico y N=20.598 registros.

CLASIFICACIÓN

La variable objetivo (C1) mide el estado de salud en los últimos 12 meses. Se plantea un problema de clasificación MultiClase con 5 niveles.

Preparación De datos

PASO 1: Identificación y asignación de tipos de variables

164 variables / features

Valor Original	Nivel
1	Muy Bueno
2	Bueno
3	Regular
4	Malo
5	Muy Malo

NOTA:

Dentro de las 150 estaba la variable objetivo la cual fue excluida del proceso de codificación y mantuvo su formato original



Categorías

Numéricas

One-Hot encoding

Sin codificación

PASO 2: Codificación

id	SEXOa
1	Hombre
2	Mujer
3	Hombre

id	Mujer	Hombre
1	0	1
2	1	0
3	0	1

Aumento de la dimensionalidad

461
variables / features

Modelos Seleccionados



MODELO BASE

K-NN

Implementado como **baseline** del proyecto. Establece una referencia inicial de rendimiento necesaria para validar la mejora de modelos posteriores.



EXPLICABILIDAD

Árbol de Decisión

Elegido por su **alta interpretabilidad**. Permite explicar visualmente las decisiones del modelo y los factores clínicos que determinan cada rama.




ESTADO DEL ARTE

XGBoost

Seleccionado para **maximizar el rendimiento predictivo**. Su arquitectura de Gradient Boosting es ideal para capturar relaciones complejas en el problema.

Metodología del desarrollo del modelo

- Como hay desbalance usamos splits estratificados por clase (70-30).
 - a. Training Set: 14,418 pacientes
 - b. Testing Set: 6,180 pacientes
- Tres etapas
 - a. Búsqueda de mejores parámetros y variables para cada modelo (Con $cv=3$ y métrica $f1$ weighted)
 - b. Entrenamiento cada modelo con mejores parámetros
 - c. Evaluación con conjunto de test para elegir el mejor modelo
- La selección de variables se hace con $f_classif$ (ANOVA F-value) con 10,15, 20 variables. Es un hiperparametro mas de la búsqueda.



K-Nearest Neighbors (K-NN)


- Mejor configuración de 900 probadas:
 - n_neighbours → 73
 - Weights → Uniforme
 - Metric → Manhattan

```
param_grid = {  
    "select__k": N_FEATURES,  
    # Parámetros del modelo KNN  
    "model__n_neighbors": list(range(1, 101)),  
    "model__weights": ['uniform'],  
    "model__metric": ['manhattan']  
}
```

split	P_W	R_W	F1_W	S
train	0.95	0.94	0.94	14418.0
test	0.55	0.57	0.55	6180.0

split	class	P	R	F1	S
train	0	0.82	0.93	0.87	2673
	1	0.96	0.93	0.94	6999
	2	1.00	0.97	0.99	3479
	3	1.00	0.99	1.00	1016
	4	1.00	1.00	1.00	251
test	0	0.50	0.42	0.46	1134
	1	0.61	0.75	0.67	3013
	2	0.53	0.47	<u>0.50</u>	1495
	3	0.42	0.14	0.22	428
	4	0.15	0.05	0.07	110

K-NN: Interpretación



- El modelo ha entendido el problema.
- El estado de salud es un espectro.
- La predicción no es igual a la realidad ("Bueno", "Regular" y "Malo" comparten características similares).

Árbol de Decisión

- Mejor configuración de 135 probadas:
 - Max depth: 5
 - Min samples split: 20
 - Mejor numero de variables: 10

```
param_grid = {  
    "select_k": N_FEATURES,  
    "model_criterion": ["gini"],  
    "model_max_depth": [5, 6, 10],  
    "model_min_samples_split": [2, 5, 10, 20, 50],  
    "model_max_features": [None],  
}
```


- No overfitting

split	P_W	R_W	F1_W	S
train	0.61	0.61	0.60	14418
test	0.59	0.60	0.59	6180

split	class	P	R	F1	S
train	0	0.59	0.39	0.47	2673
	1	0.66	0.77	0.71	6999
	2	0.57	0.57	0.57	3479
	3	0.46	0.39	0.42	1016
	4	0.50	0.23	0.32	251
test	0	0.58	0.36	0.44	1134
	1	0.65	0.76	0.70	3013
	2	0.57	0.56	<u>0.56</u>	1495
	3	0.42	0.38	0.40	428
	4	0.34	0.16	0.22	110

Árbol de Decisión: Interpretación


- Grado de limitación durante al menos 6 meses por un problema de salud: C3a_3 (Nada limitado/a)
- Rama derecha buena salud y rama izquierda mala salud
- K1_2 no usada (el modelo tiene profundidad limitada a 5)



Feature	FI
C3a_3	0.57
C2_2	0.12
ÍNDICE BIENESTAR	0.11
EDADa	0.09
C3a_2	0.06
G7_5	0.02
C5a_8_2	0.01
C5a_6_2	0.01
CUADROS DEPRESIVOS 3	0.01
K1_2	0.00


Árbol de Decisión: Rama Izquierda

- Factores de Mala salud: INDICE_BIENESTAR ≤ 14 , G7_5 (Grado de dolor severo), C2_2 = 0 (con enfermedades crónicas o no contesta)
- C2_2 = 1 (Sin enfermedades crónicas) y con edad ≤ 46 tienen buena salud



Árbol de Decisión: Rama Derecha

- Grado de limitación durante al menos 6 meses por un problema de salud: C3a_3 (Nada limitado/a)
- Factores de buena salud: Índice Bienstar ≥ 78 , Edad ≤ 45



XG Boost

- Mejor configuración de 324 probadas:
 - Numero de arboles: 50
 - Mejor numero de variables: 50
 - Subsample: 1.0 (usa todos los datos)
 - Profundidad Máxima: 5

```
param_grid = {  
    "select_k": N_FEATURES + [30, 40, 50],  
    "model_n_estimators": [5, 10, 50],  
    "model_max_depth": [5, 10, 15],  
    "model_subsample": [0.6, 1.0],  
}
```


split	P_W	R_W	F1_W	S
train	0.74	0.73	0.74	14418
test	0.64	0.65	0.64	6180

split	class	P	R	F1	S
train	0	0.64	0.34	0.44	2673
	1	0.66	0.82	0.73	6999
	2	0.60	0.61	0.61	3479
	3	0.63	0.38	0.47	1016
	4	0.61	0.32	0.42	251
test	0	0.61	0.31	0.42	1134
	1	0.65	0.80	0.72	3013
	2	0.57	0.58	<u>0.57</u>	1495
	3	0.49	0.32	0.38	428
	4	0.43	0.24	0.31	110

XG Boost: “Interpretability”

- Overfitting detectada en gráficas (early stopping recomendado)
- El modelo mejora cuanto más árboles utiliza
- Top 10 features similar a Arbol de decisión.

XGBoost Training Curves




Feature	FI
C3a_3	0.28
C2_2	0.12
C3a_2	0.10
C4_2	0.05
C4_3	0.04
K1_2	0.02
G7_5	0.02
INDICE_BIENESTAR	0.02
G7_6	0.02
CUADROS_DEPRESIVO S_3	0.02


Comparativa de Modelos: Matriz de Confusión

- Todos los modelos al ser el estado de salud bueno la clase mayoritaria es la clase con mejor rendimiento en todos los modelos.
- Árboles mejoran la clasificación de la clase minoritaria estado de salud muy malo:
 - a. 5 vs 18 vs 23 verdaderos positivos
 - b. Reducion de 12 falsos positivos con K-NN a 1 con arboles


KNN



Árbol de decisión



XG Boost



Conclusión y Líneas futuras

- Todos los modelos superan el baseline aleatorio
 - Existe capacidad predictiva real
 - Mejora progresiva (+complejo-> +mejor)
- X Boost es el mejor modelo, pero el margen (0.64) indica oportunidad de mejora
- Líneas futuras
 - Aplicar estrategias de data-preparation específicas para cada modelo. Estudiar mejor el tipo de variables categóricas para hacer una mejor codificación y no perder información ordinal.
 - Aplicar técnicas de desbalanceo

Modelo	F1_W	Acc
Random	0.33	0
K-NN	0.55	+0.22
Arbol	0.59	+0.26
XGBoost	0.64	+0.31

**MUCHAS
GRACIAS**