



Un refrán vale más que 1000 tokens

Evaluación de LLMs en cultura castellana

Sabiduría Popular Castellana @ Hackathon SomosNLP 2025



2

1

Evaluar la eficacia de los modelos de lenguaje para interpretar y transmitir el significado de refranes en castellano.

2



Analizar el impacto del ajuste fino en el desempeño de los modelos frente a sus versiones base.

3

Examinar la adecuación de las métricas de evaluación, tanto basadas en embeddings como en juicios de LLMs, para medir la comprensión semántica de los refranes.


Diseño Estudio

- Datos scrapeados de fuentes públicas, para cada refrán se ha obtenido su significado.
- Entrenamiento de modelos de generación de texto y embeddings.



Diseño Estudio

- Evaluación con similitud coseno y con *LLM-as-judge*.



Conjuntos de datos

4 conjuntos de datos

Blogs para entrenamiento

es-refranes-145

es-refranes-103

Sets de evaluación

Fine tuning testing set

es-paremi-as-236

Embeddings

es-paremi-as-variantes-antonimos

Prompting:

somosl-p-hackathon-2025/es-benchmark-prompts-refranes

Nombre	Website	Licencias
es-refranes-103	https://www.curiosidario.es/refranes-populares-espanoles/	Copyright en la página
es-refranes-145	https://psicologiymente.com/reflexiones/refranes-cortos	Copyright en la página
es-paremi-as-236	https://cvc.cervantes.es/lengua/refranero/listado.aspx	Reservados todos los derechos.
es-paremi-as-variantes-antónimos		

Conjuntos de datos

- El conjunto de evaluación *somosnlp-hackathon-2025/es-benchmark-prompts-refranes* consta de:
 - prompt system:** indicando que es un experto en refranes
 - user example:** Un 1-Shot de ejemplo.
 - prompt user:** Refrán a explicar el significado.
 - Respuesta:** Respuesta correcta solo usado para validar.

prompt_system string · classes	user_example string · classes	assistant_example string · classes	prompt_user string · lengths	Respuesta string · lengths
1 value	1 value	1 value	47 114	29 655
Eres un experto en cultura castellana, tu...	No es oro todo lo que reluce	Nos señala la importancia de no dejar llevarse por...	¿Qué significa el refrán: '¿Adónde irá el buey que...	Tomando como referente el buey, animal cuya...
Eres un experto en cultura castellana, tu...	No es oro todo lo que reluce	Nos señala la importancia de no dejar llevarse por...	¿Qué significa el refrán: '¿Adónde va la lengua?...	Igual que de modo instintivo la lengua va ...
Eres un experto en cultura castellana, tu...	No es oro todo lo que reluce	Nos señala la importancia de no dejar llevarse por...	¿Qué significa el refrán: 'A amor mal...	Se recomienda olvidar los amores que, por no tener...

Selección de modelos de embeddings

- Se estudió qué modelos de embeddings entendían más de los refranes empleando el dataset:

*somosnlp-hackathon-2025/es-
paremias-variantes-antonimos*

Modelo	Coefficiente de Pearson
Multilingual E5	0.21
Cohere embed -v4.0 dim 1024	0.68
Cohere embedded multilingual v3.0-light dim 384	0.72
Cohere embedded multilingual v3.0-light dim 1024	0.70
Multilingual E5 refranes (propio)	0.40

Configuraciones de LLMs

- Entrenamiento Tuning Perf Lora
 - a. **LoRA Config:** $r=16$, $\text{lo_alpha}=32$, $\text{dropout}=0.05$
 - b. **Training Args:** $\text{epochs}=3$, $\text{batch_size}=8$ $\text{lr}=2e-4$
 - i. Cuantización 4-bit (P100 Kaggle):
 1. Mistral-7B-v0.3-perf-lora-4bit
 2. Llama-2-7b-hf-perf-lora-4bit
 - ii. Solo Lora (L40S HF) :
 1. deepseek-llm-7b-base-perf-lora
 2. Meta-Llama-3.1-8B-perf-lora
- Entrenamiento con Cohere
 - a. command-r-03-2024-lora

Configuraciones de LLMs

Sólo inferencia

Small

deepseek-llm-7b-chat
Llama-2-7b-chat-hf
Llama-3.1-8B-Instruct
Mistral-7B-Instruct-v0.3
Qwen3-8B (razonador)
salamandra-7b-instruct

Quantizado

S

TheBloke/Llama-2-7B-GGUF
christopherBR/Llama-3-7B-Q4_K_M
Mistral-7B-Instruct-v0.3-GGUF

Large

Cohere API: command-r-03-2024,
command-r-08-2024,
command-a-03-2025

- Mejor modelo `command-a-03-2025` de cohere es el modelo más grande y mejor de cohere.
 - Diferencia de 2% mejor en similitud y 0.4 de score más que `command-r-08-2024`
- Qwen3-8B mejor modelo pequeño.

Modelo	embed-multilingual-light-v3.0-sim	multilingual-e5-base-sim	multilingual-e5-refranes-sim	command-a-03-2025-score	Rank
command-a-03-2025	0.553	0.866	0.838	3.605	1
command-r-08-2024	0.533	0.867	0.836	3.215	2
command-r-03-2024	0.543	0.867	0.836	3.207	3
command-r-03-2024-lora	0.497	0.854	0.821	2.89	4
Qwen3-8B	0.53	0.848	0.806	2.711	5
salamandra-7b-instruct	0.493	0.857	0.825	2.685	6
Llama-3.1-8B-Instruct	0.507	0.85	0.825	2.529	7
Mistral-7B-Instruct-v0.3	0.489	0.839	0.767	2.373	8

* **sim**: Distancia coseno (0-1, donde 0 nada de similar)

* **score**: LLM-as-judge (1-5 multiplicado por log probs (donde 1 es puntuación mínima).

- Modelos fine tuneados y cuantizados peores resultados que modelos base.
- Entre *Mistral-7B-Instruct-v0.3-GGUF* y *Mistral-7B-Instruct-v0.3* hay una diferencia marginal
 - **sim**: 0.489 y 0.488
 - **score**: 2.373 y 2.337

Modelo	embed-multilingual -light-v3.0-sim	multilingual-e5 -base-sim	multilingual-e5 -refranes-sim	command-a -03-2025-score	Rank
Mistral-7B-Instruct-v0.3-GGUF	0.488	0.827	0.795	2.337	9
deepseek-llm-7b-chat	0.496	0.839	0.808	2.32	10
Llama-2-7b-chat-hf	0.477	0.828	0.788	2.164	11
Llama-3-7B-Q4_K_M	0.488	0.838	0.795	2.09	12
Mistral-7B-v0.3-lora-4bit-refranes	0.459	0.837	0.8	2.008	13
Llama-2-7B-GGUF	0.453	0.831	0.794	1.748	14
Llama-2-7b-hf-lora-refranes	0.395	0.817	0.784	1.578	15
deepseek-llm-7b-base-lora-refranes	0.315	0.791	0.749	1.308	16
Meta-Llama-3.1-8B-lora-refranes	0.283	0.781	0.741	1.144	17

Hallazgos

- Las métricas basadas en *embeddings* no siempre reflejan bien el verdadero significado, ya que son sensibles a variaciones lingüísticas superficiales.
- Además, el ajuste fino de los modelos con conjuntos de datos de naturaleza semántica distinta no conduce a mejoras significativas en el rendimiento, lo que sugiere una limitada transferencia cuando existe una discrepancia en el estilo o la expresión cultural.

Trabajo futuro

- Incorporar la **evaluación humana** para complementar las métricas automáticas y captar mejor el verdadero significado.
- Unificar la **adecuación cultural** de los datasets de entrenamiento y evaluación, ya que las diferencias de estilo afectan la calidad de las métricas basadas en embeddings, incluso cuando el significado es el mismo.

Datasets usados para entrenar

- <https://huggingface.co/datasets/somosnlp-hackathon-2025/es-refranes-145>
- <https://huggingface.co/datasets/somosnlp-hackathon-2025/es-refranes-103>

Dataset de embeddings

- <https://huggingface.co/datasets/somosnlp-hackathon-2025/es-paremi-as-variantes-antonimos>

Dataset usado para evaluar

- <https://huggingface.co/datasets/somosnlp-hackathon-2025/es-paremi-as-236>

Demo

- <https://huggingface.co/spaces/somosnlp-hackathon-2025/DemoRefranesCastellano>



Un refrán vale más que 1000 tokens

Evaluación de LLMs en cultura castellana

Sabiduría Popular Castellana @ Hackathon SomosNLP 2025

¡Gracias por vuestra atención!

Álvaro García Barragán, Laura del Pino Díaz, Laura Masa Martínez, Enrique Solera Navarro y Alberto González Calatayud

Demo Space HF

 Spaces |  somosnlp-hackathon-2025 / **DemoRefranesCastellano**   like 0  Running on T4  Logs

App | Files | Community | Settings |  

Sabiduría Popular - Refranes

Esta aplicación explica el significado de refranes en español utilizando un modelo de lenguaje. Escribe un refrán y el modelo te explicará su significado.

 Chatbot

A caballo regalado no le mires el diente

Más vale pájaro en mano que ciento volando

Quien a buen árbol se arrima, buena sombra le cobija

No por mucho madrugar amanece más temprano

Type a message... 

Additional Inputs 

Usar vía API  · Construido con Gradio  · Configuración 