



Máster en
Bioinformática

AlphaGenome para interpretar variantes genéticas en cáncer de pulmón


Álvaro García Barragán

Data & Computer Scientist in Health

12-05-2026 Escuela Nacional de Sanidad, Madrid, España

Índice


1. Introducción
2. Conceptos generales
3. Arquitectura
4. Entrenamiento
 - 4.1. Knowledge Distillation
 - 4.2. Data Augmentation
 - 4.3. Detalles Computacionales
5. Evaluación
6. Código
7. Caso de uso: Análisis de variantes en cáncer de pulmón



Introducción

El ADN tiene 3,200 chunks de 1 Mb

- Interpretar la **variación genética** es un **gran desafío**, especialmente las variantes no codificantes
 - **3.2 B de Bases = {A, T, C, G}**, $|Bases| = 4$
 - **c**: 20 AMs $\rightarrow$ 20,000 genes $\rightarrow$ 20 M de proteínas
 - **nc**: $\sim 98\%$ de las variantes son no codificantes
- Una **variante no codificante** (reguladora) puede tener efectos a **múltiples niveles biológicos** (modalidades de datos)
 - Modifican la expresión génica
 - Alteran el splicing del ARN
 - Afectan la cromatina y su estructura 3D
 - Sus efectos dependen del tipo celular
- El **$\sim 99\%$ de las interacciones** entre los pares potenciador-gen ocurren dentro de una distancia de **1 Megabase (1 Mb $\sim 10^6 \sim 2^{20}$)**



<https://biotech-careers.org/article/why-non-coding-rna-hot-biotechnology>

Paper

- **AlphaGenome**: es un modelo *multimodal* (unificado) de *aprendizaje profundo* (DL) diseñado para *predecir el efecto de variantes reguladoras* del ADN (*Variant Effect Prediction*)
- Desarrollado por Google DeepMind (Enero 2026)

Article | [Open access](#) | Published: 28 January 2026

Advancing regulatory variant effect prediction with AlphaGenome

[Žiga Avsec](#) , [Natasha Latysheva](#), [Jun Cheng](#), [Guido Novati](#), [Kyle R. Taylor](#), [Tom Ward](#), [Clare Bycroft](#), [Lauren Nicolaisen](#), [Eirini Arvaniti](#), [Joshua Pan](#), [Raina Thomas](#), [Vincent Dutordoir](#), [Matteo Perino](#), [Soham De](#), [Alexander Karollus](#), [Adam Gayoso](#), [Toby Sargeant](#), [Anne Mottram](#), [Lai Hong Wong](#), [Pavol Drotár](#), [Adam Kosior](#), [Andrew Senior](#), [Richard Tanburn](#), [Taylor Applebaum](#), ... [Pushmeet Kohli](#) 

+ Show authors

Nature **649**, 1206–1218 (2026) | [Cite this article](#)

349k Accesses | **69** Citations | **1234** Altmetric | [Metrics](#)




Aplicación

- Un modelo unificado que combina **contexto de 1 Megabase (Mb)** a **resolución de 1 pb**
- Procesa un *chunk* de ADN (1Mb) y lo "proyecta" en miles de tracks (**5,930 humanos y 1,128 de ratón**) con diferentes niveles de detalle (resolución) según la necesidad biológica de cada modalidad.
 - Gene Expression: RNA-seq tracks 667 humanos y 173 tracks de ratón. (diff. tipos de tejidos)
- **11 modalidades biológicas diferentes:** Expresión Génica, Procesamiento del ARN (Splicing), Accesibilidad y Estado de la Cromatina, Mapas de contacto de la cromatina

Secuencias de referencia:




- hg38
- mm10



Aplicación: Predicciones en línea celular HepG2 (hígado)


- A. Ejemplo de predicciones en una región de 1 Mb en chr. 19
- B. Predicciones de splicing (cuanto y donde)
- C. Rendimiento fiable
 - a. *Pearson r* promedio: **> 0.50**;
 - b. *Pearson r* RNA-seq: **0.81** (humano y ratón)

Capacidad de obtener el RNA-seq, ATAC o splice junctions a partir de un ADN seq



Arquitectura: U-Net + Transformers


- Capas convolucionales y de atención
 - Backbone inspirado en **U-Net para manejar múltiples escalas**
(Encoders & Decoders)
 - **Torre de Transformers para modelar interacciones de largo alcance**
- Generación de representaciones internas
 - **Embeddings 1D** (res. de 1 pb y 128 pb), que corresponden a representaciones del genoma lineal
 - **Embeddings 2D** (res. de 2.048 pb), que corresponden a representaciones de las interacciones espaciales entre segmentos genómicos



Arquitectura: Resoluciones

- La resolución determina el nivel de detalle con el que se analiza la señal del ADN
 - **Alta (1 pb)**: muestra picos precisos pero con más ruido
 - **Baja (128 pb)**: suaviza la señal y pierde detalles
- En estudios de expresión génica, una resolución alta permite identificar sitios específicos, y una baja facilita ver tendencias generales más estables
 - Depende de la modalidad biología unas resolución son mejores que otras

A G T T G C A A T T G G
1 bp
12 bp



Species Identity determinar qué conjunto de pistas genómicas debe generar


Input

- **Tuple one-hot encoded**
($2^{20}, 4$)
4 DNA nucleotides
(A, C, G, T)
- **Species Identity**
(human, mouse)


Outputs (Múltiple)

- **High resolution** 1bp
($2^{20}, \# \text{ tracks}$)
- **Low Resolution** 128 bp
($2^{13} \text{ bp}, \# \text{ tracks}$)
- **2D Spatial Interactions**
2,048 bp
($2^9, 2^9, \# \text{ tracks}$)
- **Splice Junction Head**
1bp (512, 512, 734)

a AlphaGenome Model Overview




b Detailed diagrams for key model components



Arquitectura U-NET


Desarrollada para segmentar imágenes, la red aprende a diferentes resoluciones (contexto global y detalles)



Arquitectura: Detalles computacionales

~3200 s (~53 mins) en procesar un genoma completo

- **Entrenamiento**
 - **División en fragmentos:** La secuencia de entrada de 1 Mb se divide en **8 fragmentos de 131 kb cada uno**.
 - **Procesamiento distribuido:** Estos fragmentos se procesan simultáneamente a través de ocho dispositivos TPU v3 interconectados (Tensor Process Units)
 - Mantientine la resolución de 1 bp en una ventana de contexto de 1 Mb **sin agotar la memoria** de un solo dispositivo (TPU).
- **Inferencia en un solo paso en <1s** en una GPU NVIDIA H100 (predicciones para todas las modalidades)




Entrenamiento: Knowledge Distillation

Estudiante comprime toda la sabiduría en un modelo

- El entrenamiento en dos fases:
 - Pre-entrenamiento (Fase de los Maestros):**

Se entrenan modelos utilizando **datos experimentales observados**.

 - 4 modelos** por *folds* para validación cruzada (**4-fold cv**)
 - 64 modelos All-fold** con distintas semillas (*teacher ensemble*) -> no eval
 - Destilación (Fase del Estudiante):**
 - Un **único modelo estudiante** que comparte la misma arquitectura que los maestros.
 - Su objetivo es aprender a **reproducir las predicciones** del *teacher ensemble*.



Entrenamiento: Data Augmentation


→ Mejora de la generalización

◆ **Reverse Complement (50%):** El modelo procesa la secuencia original o su complemento inverso con una probabilidad del 50% durante el entrenamiento.

- Reconocer motivos y elementos regulatorios independientemente de la hebra de ADN

◆ **Random Shift:** Consiste en variar ligeramente la posición de inicio del intervalo de 1 Mb muestreado del genoma

- Evitar que el modelo aprenda sesgos basados en la alineación exacta de los datos experimentales




Entrenamiento: Random Mutations

→ Precisión predictiva en variantes genéticas reales

◆ Entrenamiento con Mutaciones Artificiales:

Los datos experimentales de laboratorio suelen ser de genomas "sanos" o de referencia. Si el estudiante solo aprendiera de ellos, no sabría qué pasa cuando el ADN cambia (muta)

- Durante la destilación, se le dan al estudiante secuencias con mutaciones aleatorias.
- El **estudiante debe adivinar cómo reaccionaron los maestros** ante ese cambio.



Entrenamiento: Detalles computacionales

- Optimizador: AdamW ($\beta_1=0.9$, $\beta_2=0.999$, $\epsilon=1e-8$) (default hyperparameters)


- **Pre-entrenamiento (68 models = 64+4)**

- Duración: 15,000 pasos (~4h)
- Learning rate
 - Warm-up lineal $\rightarrow 0.004$ (5k pasos)
 - Decaimiento coseno $\rightarrow 0$ (10k pasos)
- **512 TPUv3** cores
- Entrenamiento en 4 folds + modelos *All-folds*

- **Distillation (1 model)**


- Duración: 250,000 pasos (~3 días)
- Learning rate
 - Warm-up $\rightarrow 0.002$ (5k pasos)
 - Constante (120k pasos)
 - Decaimiento coseno (125k pasos)
- **64 GPUs** (NVIDIA H100), batch size 64
- Cada GPU usa un modelo teacher distinto

1 PM = 512 TPUv3 x 4h x 2 USD/h = 4,100 USD
68 PM x 4,100 USD / PM = **262,400 USD**
64 GPUs H100 x 72h x 3.5 USD/h = **16,128 USD**



Evaluación: Benchmarking with SOTA

- **Superó o igualó** a los mejores modelos especializados **en 25 de 26 evaluaciones** de predicción de efectos de variantes, incluyendo tareas de splicing, expresión génica y estado de la cromatina




Pretrained 4-fold cv

Distilled all-fold model

Evaluación: Estudios de ablación

- A. **Resolución del objetivo:** Resolución de 1 bp es mejor en tareas de alta precisión
- B. **Longitud de secuencia:** Entrenar y evaluar con secuencias largas (1 Mb) es mejor
- C. **Ensembles vs. destilación vs. #models:** modelo destilado con 64 maestros es mejor
- D. **Aprendizaje multimodal:** mejor o igual que unimodal



Código

- Código abierto en: <https://github.com/google-deepmind/alphagenome>
- Documentación: <https://www.alphagenomedocs.com>
- Quick Start: https://colab.research.google.com/github/google-deepmind/alphagenome/blob/main/colabs/quick_start.ipynb

The screenshot shows the GitHub repository page for 'alphagenome'. The repository is public and has 33 watchers, 259 forks, and 1.9k stars. The main branch is selected, and there are 10 tags. The repository description states: 'This API provides programmatic access to the AlphaGenome model developed by Google DeepMind.' The file list includes: .github, colabs, docs, scripts, src/alphagenome, .gitattributes, .pylintrc, and .readthedocs.yaml. The right sidebar shows the 'About' section with links to the README, Apache-2.0 license, Contributing, Activity, Custom properties, and repository statistics.

alphagenome Public

Watch 33 Fork 259 Starred 1.9k

main 1 Branch 10 Tags

Go to file Add file Code

QEDady and copybara-github Remove obsolete : ... from all python functions p... 34d166b · 3 weeks ago 99 Commits

File	Description	Commit Date
.github	Copybara import of the project:	4 months ago
colabs	Add a Colab notebook to demonstrate how to score splicing ...	2 months ago
docs	Add a Colab notebook to demonstrate how to score splicing ...	2 months ago
scripts	Add support for processing splice sites from GTF.	4 months ago
src/alphagenome	Remove obsolete : ... from all python functions parameters...	3 weeks ago
.gitattributes	Initial commit.	11 months ago
.pylintrc	Initial commit.	11 months ago
.readthedocs.yaml	Initial commit.	11 months ago

About

This API provides programmatic access to the AlphaGenome model developed by Google DeepMind.

www.alphagenomedocs.com

Readme

Apache-2.0 license

Contributing

Activity

Custom properties

1.9k stars


33 watching

259 forks

Report repository

Caso de Uso: Cáncer de pulmón

- **Caso Clínico:** Paciente diagnosticado con cáncer de pulmón de células escamosas avanzado ([HP:0030359](#)), Estadio IV con metástasis cerebral.
- 505 variantes -> 24 tras filtrar con anotación en Ensembl VeP (significancia clínica != Nula)
 - 5 variantes patogénicas y 2 variantes benignas
 - 17 anotaciones para variantes vus -> 14 variantes vus




Caso de Uso: Predicción de variantes patogénicas

- **Variante patogénica:** chr17:31200422:A>T, Gen NF1, Stop gained variant
- AlphaGenome predice la expresión en tracks de Pulmón ([UBERON:0002048](#))
 - 2 muestras adultas (hebras +-, polyA plus RNA-seq)
 - 2 embrionarias (hebras +-, total RNA-seq)
- La expresión de la variante (**rojo**) es menor que la referencia (**gris**)
 - **Gen NF1 down-regulado**

```
variant_output = dna_model.predict_variant(  
    interval=interval,  
    variant=variant,  
    requested_outputs=[dna_client.OutputType.RNA_SEQ],  
    ontology_terms=[  
        'UBERON:0002048',  
    ]  
)
```


Gen NF1,
supresor de
tumores



Caso de Uso: Predicción de variantes patogénicas


- **Variante patogénica:** chr11:534285:C>A , Gen HRAS, missense variant
- El cambio del nucleótido genera otra proteína pero la expresión es parecida
- Track RNA-seq hebra positiva de embryonic no se expresa (< 0.004)
- Track RNA-seq hebra negativa de embryonic se expresa más en ALT que REF
 - **Gen HRAS up-regulado**

Gen HRAS,
proliferación
celular



Caso de Uso: Estudió variantes vus

- **Variante vus:** chr14:102928953:G>A , Gen AMN, missense variant
 - Amnionless ayuda al organismo a absorber la vitamina B12
 - La B12 participa en la **síntesis de ADN y división celular**
- Gen AMN con cromatina accesible en track ATAC (Assay for Transposase-Accessible Chromatin)



Caso de Uso: Scoring de variantes vus

- **Variante vus:** chr14:102928953:G>A , Gen AMN, missense variant
- La API de AlphaGenome permite scoring de variantes
 - **raw_score** se calcula como el LFC de la señal de RNA-seq entre ALT y la REF
 - **quantile_score** es una normalización de raw_score
- lncRNA LINC00605: ARN largo no codificante con función de regulación (no estudiado)
 - Cambio LFC bajo pero top ~3–5% del ranking -> posible efecto regulador (no codificante)
 - lncRNA LINC00673: **Promueve la metástasis de cáncer de pulmón** (estudiado)

```
dna_model.score_variant(  
    interval=interval,  
    variant=variant,  
    variant_scorers=[rna_seq_variant_scorer]  
)
```

Generación de hipótesis de investigación
¿La variante chr14:102928953:G>A influye en
el lncRNA LINC00605 a 72 kb de distancia?

Long intergenic noncoding RNA 00673 promotes non-small cell lung cancer metastasis by binding with EZH2 and causing epigenetic silencing of HOXA5

[PDF](#) | [Full Text](#) | [Supplementary Files](#) | [How to cite](#)

Oncotarget. 2017; 8:32696-32705. <https://doi.org/10.18632/oncotarget.16158>

gene_name	gene_strand	biosample_name	biosample_life_stage	gene_type	raw_score	quantile_score
LINC00605	-	lung	embryonic	lncRNA	0.003253	0.949106
LINC00605	-	lung	adult	lncRNA	0.005297	0.974781

Aplicaciones y Potencial

- Motor de **experimentación virtual e interpretación genómica** para comprender cómo las secuencias de ADN y sus variaciones dictan la función celular (*digital twin del genoma*)
 - **Investigación de enfermedades raras:** Proporcionando evidencia funcional para variantes de significado incierto (vus)
 - **Diseño de secuencias:** Acelerando la creación de oligonucleótidos terapéuticos o potenciadores específicos para tejidos (simular knock-outs para CRISPR)
 - **Descubrimiento biológico:** Motor de experimentación in silico para generar hipótesis rápidas antes de pasar al laboratorio
- Métodos técnicos
 - **Mutagénesis in silico (ISM):** Técnica computacional que permite predecir los efectos de todas las posibles variaciones de un solo nucleótido (SNV) en una región específica de una secuencia de ADN
 - Explotar el significado biológico aprendido (**variants embeddings**)
 - Similitud entre variantes (**Búsquedas Genómicas**)
 - Agrupar fragmentos de ADN (**Clustering Genómico**)



Máster en
Bioinformática

AlphaGenome para interpretar variantes genéticas en cáncer de pulmón

Álvaro García Barragán

Data & Computer Scientist in Health

12-05-2026 Escuela Nacional de Sanidad, Madrid, España